Abajo encontrarán un poco de intuición sobre la sección "1. Estimación de la pose de una cámara" y la subsección "2.1. DLT en 3 dimensiones". Este PDF es simplemente una ayuda que decidimos hacer con el profesor Pablo Negri para que arrancar el TP sea un poco más ameno. Arrancamos,

El TP se basa simplemente en proyectar objetos del mundo real (3D) en una imagen (2D).

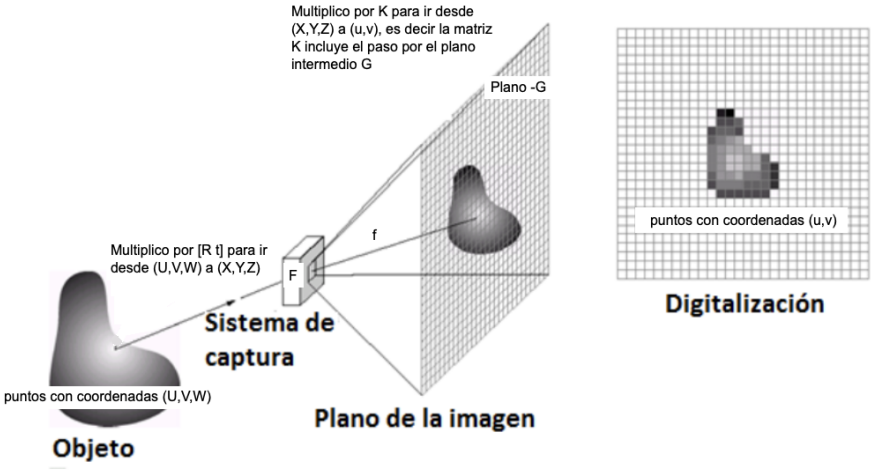
En el TP conviven dos sistemas de coordenadas 3D distintos: (U, V, W) y (X, Y, Z).

La notación (U, V, W) debe entenderse como el sistema de coordenadas del mundo real: supongamos que el objeto a proyectar es una habitación con forma de cubo de $10m$ de ancho, $10m$ de largo y $10m$ de altura. [DIBUJAR CUBO EN PIZARRON SENALANDO UNA ESQUINA COMO EL $(0, 0, 0)$]. Entonces el $(0, 0, 0)$ podría ser, por ejemplo, la esquina inferior izquierda. Y tanto U, V y W están acotados entre 0 y 10. Por ejemplo, el punto $(5, 5, 0)$ sería el piso en el centro de la habitación mientras que el $(5, 5, 10)$ sería el techo en el centro de la habitación.

La notación (X, Y, Z) se refiere el sistema de coordenadas de la cámara. El origen $(0, 0, 0)$ es el propio centro de la lente de la cámara, a quien llamamos F, es decir $F := (0, 0, 0)$. Por qué es importante este F? Porque hacia allí van todos los rayos/rectas que vienen del objeto a fotografiar. Y ojo acá: las coordenadas (X, Y, Z) NO son la posición de la cámara, sino la posición del objeto en el espacio medida relativa a la lente de la cámara. Si un punto está a $2m$ a la derecha de la lente, $1m$ arriba y $15m$ hacia adelante, entonces en este sistema tiene coordenadas $(X = 2, Y = 1, Z = 15)$. Noten que el eje óptico de la cámara apunta en la dirección $+Z$, por lo que cuando Z es negativo estamos detrás del centro de la lente F, y el mundo real visible solo se encuentra en Z positivo.

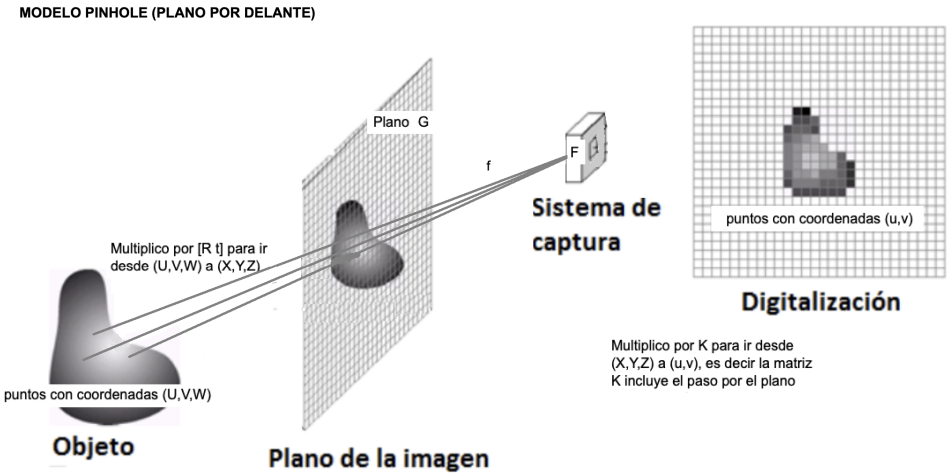
En una cámara de verdad, cualquier objeto del mundo real llega como una recta que pasa por la lente F y continúa hacia atrás hasta impactar en un sensor a distancia $-f$, haciendo que la imagen quede dada vuelta.

Modelo común:



Pero en este modelo matemático (pinhole) se hace un truco: ponemos el plano imagen G ADELANTE de la lente, a distancia $+f$ (en $Z = f$). O sea, el rayo de luz que va al foco F impacta primero en este plano G antes de llegar a la lente. De esta forma, la imagen no queda invertida y tiene exactamente el mismo tamaño.

Modelo que usamos (pinhole). [OJO QUE ACA EL PLANO G DEBERÍA ESTAR INVERTIDO PARA QUE ESTO ESTE PERFECTO PERO ERA DIFICIL DE HACER DE LOGRAR]:



El punto de impacto en este plano tiene coordenadas métricas (X', Y'), donde $X' = f\frac{X}{Z}$ e $Y' = f\frac{Y}{Z}$ por semejanza de triángulos. Cómo puedo verlo mejor si olvidé semejanza de triángulos? Cada rayo/recta va desde algún punto (X, Y, Z) hasta $(0, 0, 0)$, pasando por el medio por el plano $Z = f$. Es decir cualquier punto de ese rayo/recta puede ser escritor como (tX, tY, tZ) con $0 \leq t \leq 1$. Cuando $tZ = f$ impacta en el plano G. Reemplazando obtengo $t = f/Z$. O sea que, reemplazando t, impacta

en el plano en el punto $(f/Z \;\; X, f/Z \;\; Y, f)$. Fijense que acá ya apareció la división por Z. Como una matriz solo puede sumar y multiplicar y no puede dividir por una variable, el truco algebraico es mandar esa Z al lado izquierdo como factor de escala: de ahí sale que $\lambda = Z$ (lo vamos a ver abajo).

Para pasar de estas coordenadas 3D de la cámara (X, Y, Z) directamente a las coordenadas de píxeles (u, v), se utiliza la matriz de parámetros intrínsecos K de la cámara. Esta matriz simplemente nos detalla la información interna de la cámara en numeritos (como la distancia focal f, el tamaño de los píxeles y el centro de la imagen). Esta matriz es relevante porque imaginen que tienen dos cámaras distintas que toman una imagen desde exactamente el mismo lugar. Ambas fotos resultantes van a ser distintas porque las cámaras difieren. Entonces necesito información precisa de la cámara con la que estoy tomando la foto; y esta información se encuentra expresada en la matriz K.

Entonces, partimos de un vector $(U, V, W, 1)$, donde el 1 lo agregamos simplemente para poder multiplicar de una por la matriz de rotación y el vector de traslación. Entonces, $[R \quad t][U, V, W, 1]^T$ nos pasa el punto (U, V, W) del mundo al sistema de coordenadas de la cámara (X, Y, Z). Luego, multiplicamos directamente por K, que hace dos cosas al mismo tiempo: proyecta en perspectiva (ya que contiene la distancia focal f) y luego nos da la información en píxeles (u, v).

λ es únicamente una variable auxiliar para plantear la transformación como un producto matricial lineal (de hecho, algebraicamente vale $\lambda = Z$, la profundidad del objeto respecto a la lente). Esto lo podemos ver mejor así:

$M := K[R \quad t]$ que se aplica al punto 3D $P := [U, V, W, 1]^T$ que queremos proyectar. O sea M hace todo junto: pasar al sistema de coordenadas de la cámara y luego pasar a la imagen $2D$. Entonces, intuitivamente, tendríamos:

$$[u, v, 1]^T = M\ P \qquad \text{OJO QUE ESTO ESTA MAL}$$

pero noten que aquí hay un problema: si computo lo de la derecha $(M\ P)$ obtengo un vector cuyo tercer elemento no es 1, sino la profundidad Z del punto (las matrices solo multiplican y suman, no pueden dividir por una variable).

Si lo mirás con la descomposición física $M = K[R \mid t]$, primero $[R \mid t]P$ te da las coordenadas de la cámara:

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = R \begin{bmatrix} U \\ V \\ W \end{bmatrix} + t$$

Y luego K multiplica a (X, Y, Z) :

$$MP = K \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} \alpha_u & 0 & u_0 \\ 0 & \alpha_v & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} \alpha_u X + u_0 Z \\ \alpha_v Y + v_0 Z \\ Z \end{bmatrix}$$

Fijate que la tercera fila da exactamente Z, que es por lo que $\lambda = Z$. Entonces en realidad lo que teníamos es:

$$\begin{aligned} \lambda [u, v, 1]^T &= M\ P \\ &= \begin{bmatrix} \alpha_u X + u_0 Z \\ \alpha_v Y + v_0 Z \\ Z \end{bmatrix} \end{aligned}$$

Al dividir todo por λ, se cancela y nos quedan los píxeles u y v finales:

$$\begin{aligned} \lambda u &= \alpha_u X + u_0 Z \\ \lambda v &= \alpha_v Y + v_0 Z \\ \lambda &= Z \end{aligned}$$

Reemplanzando λ obtengo:

$$\begin{aligned} u &= \alpha_u \frac{X}{Z} + u_0 \\ v &= \alpha_v \frac{Y}{Z} + v_0 \end{aligned}$$

Y como la tercera fila de MP es precisamente $m_3^T P = Z$, esto equivale exactamente a la notación compacta del TP: $u = \frac{m_1^T P}{m_3^T P}$ y $v = \frac{m_2^T P}{m_3^T P}$.

Comentarios de Noelia:

En el ejercicio de calibración 3d: `detected_corners.txt` contiene 1 fila por imagen, por cada imagen 12 puntos detectados (u, v) por lo tanto hay 24 columnas.

En el ejercicio 2 al descomponer M como $M = K \cdot [R \mid t]$:

1. Pensar en como $M = [A \mid b]$ con $A = M[:, :3]$ (3×3) y $b = M[:, 3]$ (3×1) y usar el método QR.

2. Pensar en qué condiciones debe cumplir la matriz K, ¿cómo dijimos que eran los valores de la matriz K? Asegurarse que: 1) Necesitamos $\alpha_u > 0$, $\alpha_v > 0$ y 2) $K[2, 2] = 1$.

3. Verificar qué condiciones debe cumplir la matriz R. Una matriz que cumple $RR^\top = I$ no necesariamente es una rotación. Revisar las diferencias entre una reflexión y una rotación? ¿Qué pasa con el signo del determinante?